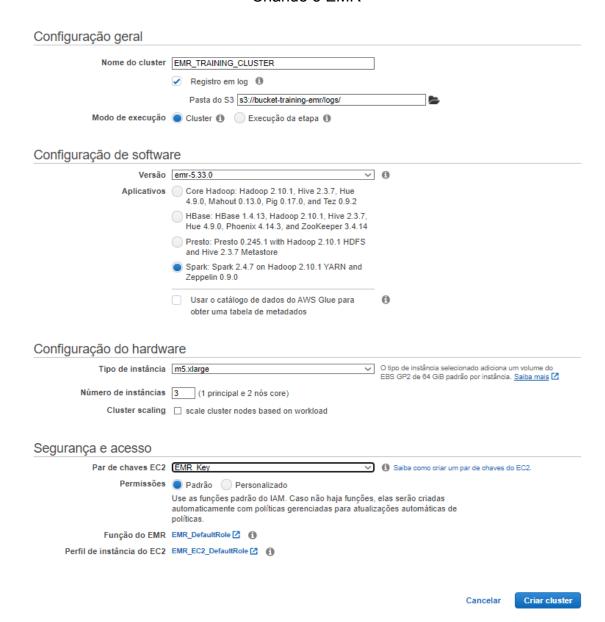
SEMANA 06 SPRINT 3 COMPASSO RAFAEL IGNAULIN

01) Curso AWS Data analytics fundamentals.

02) Vídeo

03) Criação do serviço EMR, e execução de um script para transformação de dados de um csv.

Criando o EMR



Criando e executando a etapa de app do spark, utilizando o script PySpark, o csv de entrada e uma pasta para saida de dados.

s-8RPX4QEYD25B Aplicativo do Spark Concluído 2021-06-23 15:01 (UTC-3) 32 segundos

Arquivos criados

- _SUCCESS
- part-00000-2a77c535-64ae-4ec5-8e57-78094d0cb9d9-c000.csv

name,total_red_violations
SUBWAY,322
T-MOBILE PARK,315
WHOLE FOODS MARKET,299
PCC COMMUNITY MARKETS,251
TACO TIME,240
MCDONALD'S,177
THAI GINGER,153
SAFEWAY INC #1508,143
TAQUERIA EL RINCONSITO,134
HIMITSU TERIYAKI,128

Criando o Crawler

Crawlers > glue-demo-crawler

Editar

Nome glue-demo-crawler

Descrição

Crie um único esquema para cada caminho do S3 false

Table level

Configuração de segurança

Tags

Estado Running

Programação

Last updated Wed Jun 23 14:42:54 GMT-300 2021 Date created Wed Jun 23 14:42:54 GMT-300 2021

Banco de dados glue-demo-db

Função de serviço service-role/AWSGlueServiceRole-Training-Glue

Classificadores selecionados

Datastore S3

Incluir caminho s3://emr-helloworld-rafael/read

Connection

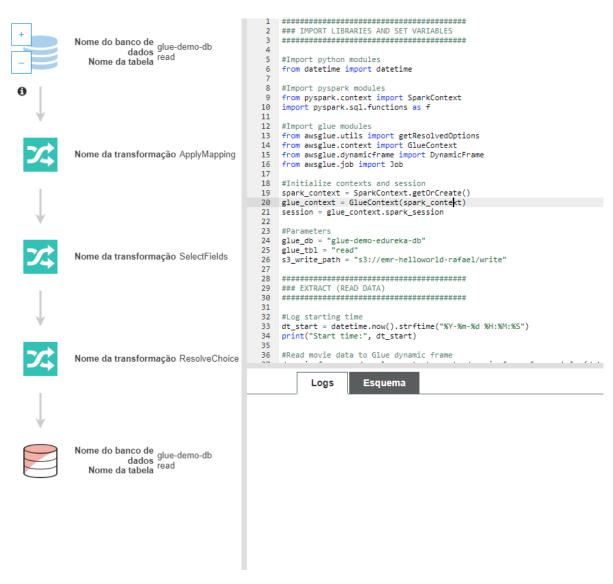
Excluir padrões

Opções de configuração

Atualizações de esquema no datastore Atualizar a definição da tabela no catálogo de dados.

Exclusão de objetos no datastore Marcar a tabela como suspensa no catálogo de dados.

Criando o Job usando script PySpark Personalizado



Após criação do Job com script personalizado, foi executado e retornou os seguintes valores no bucket de escrita:

|decade|movie_count|rating_mean| | 1990| 4| 8.95| | 2000| 3| 8.9| | 1970| 2| 9.1| | 1950| 1| 8.9|

Gerando o crawler:



Após gerar o crawler diretamente no food.csv , foi gerado o job utilizando o script pyspark fornecido.

```
import argparse
from pyspark.sql import SparkSession
 def calculate_red_violations(data_source, output_uri):
    Processes sample food establishment inspection data and queries the data to find the top 10 establishments
    with the most Red violations from 2006 to 2020.
     :param data_source: The URI where the food establishment data CSV is saved, typically
               an Amazon S3 bucket, such as 's3://DOC-EXAMPLE-BUCKET/food-establishment-data.csv'.
     :param output_uri: The URI where the output is written, typically an Amazon S3
                       bucket, such as 's3://DOC-EXAMPLE-BUCKET/restaurant_violation_results'.
    with SparkSession.builder.appName("Calculate Red Health Violations").getOrCreate() as spark:
         # Load the restaurant violation CSV data
         if data source is not None:
            restaurants_df = spark.read.option("header", "true").csv(data_source)
        # Create an in-memory DataFrame to query
         restaurants_df.createOrReplaceTempView("restaurant_violations")
         # Create a DataFrame of the top 10 restaurants with the most Red violations
         top_red_violation_restaurants = spark.sql("SELECT name, count(*) AS total_red_violations " +
           "FROM restaurant_violations "
           "WHERE violation_type = 'RED' " +
           "GROUP BY name
          "ORDER BY total red violations DESC LIMIT 10 ")
         # Write the results to the specified output URI
        top_red_violation_restaurants.write.option("header", "true").mode("overwrite").csv(output_uri)
if __name__ == "__main__":
    parser = argparse.ArgumentParser()
    parser.add_argument(
         '--data_source', help="The URI where the CSV restaurant data is saved, typically an S3 bucket.")
```

OBS: Estaremos usando o mesmo script e a mesma fonte de dados utilizada no exercício 03, só que dessa vez não usando o Elastic MapReduce e sim o Glue.

part-00000-5090bf94-8c65-4720-933e-7cac9c6e3aeb-c000.csv

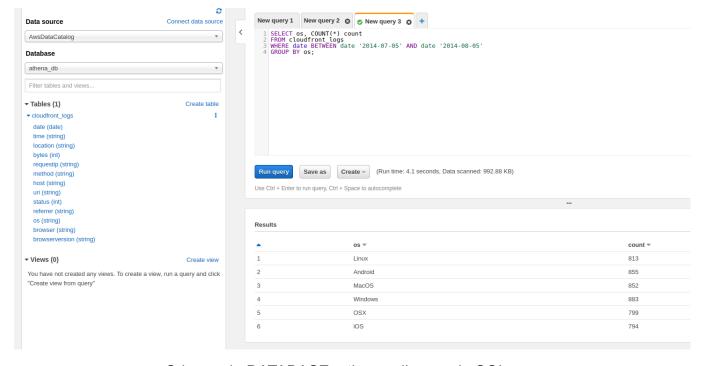
name,total_red_violations
SUBWAY,322
T-MOBILE PARK,315
WHOLE FOODS MARKET,299
PCC COMMUNITY MARKETS,251
TACO TIME,240
MCDONALD'S,177
THAI GINGER,153
SAFEWAY INC #1508,143
TAQUERIA EL RINCONSITO,134
HIMITSU TERIYAKI,128

Gerou o mesmo resultado do exercício anterior

06)
Agendando o JOB do exercicio passado, toda dia as 13:30 um gatilho é acionado para execução do job.

	Propriedades do gatilho			
Nome Tags	AgendarJob -			
Tipo do gatilho Programação	-			
Trabalhos a serem iniciados				
	Trabalitos a serent fillolados			
Trabalhos	king-country-glue			
Trabalhos	king-country-glue			
Trabalhos				
Trabalhos	king-country-glue			

INTRODUÇÃO AO ATHENA



- -Criação do DATABASE athena_db usando SQL
 - -Criação da Tabela cloufront logs usando SQI
- -Fazendo uma consulta retornando a quantidade de vezes que cada OS possui.

08)

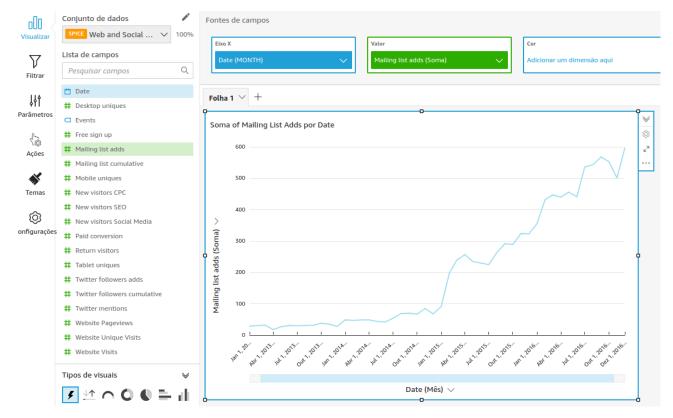
09) Views do exercício 07

```
CREATE VIEW browsers AS
SELECT
Browser,
COUNT(*) count
FROM cloudfront_logs
GROUP BY Browser;
```

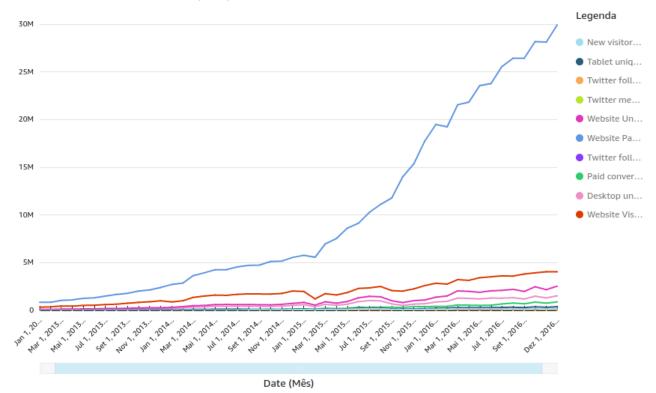
▼	Browser ▼	count 🕶
1	Lynx	889
2	Safari	875
6	Opera	835
3	Chrome	828
4	Firefox	795
5	IE	774

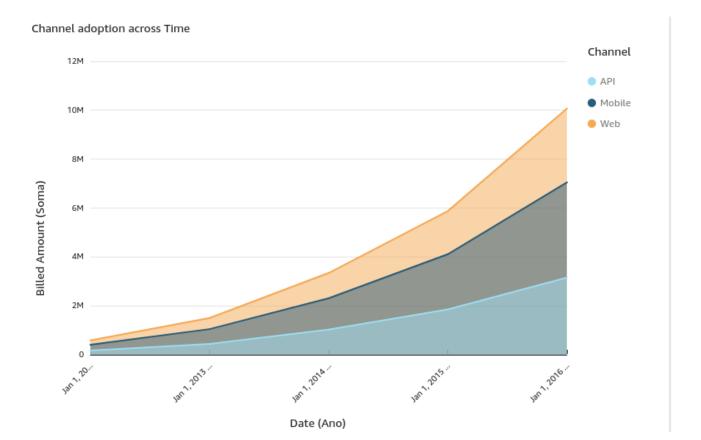
QUICKSIGHT

- Feito a análise com os dados do tutorial, selecionado no eixo X a data (agrupada por mês), e no eixo Y foi feito a soma das Adições da Lista de emails (por mês)



Soma of Website Visits, Soma of Desktop Uniques, Soma of Paid Conversion, Soma of Twitter Followers Cumulative, Soma of Webs...





Revisar

Revise suas escolhas. Depois de criar o usuário, você pode visualizar e fazer download da senha e da chave

Detalhes do usuário

Nome de usuário Administrator

Tipo de acesso AWS Acesso ao Console de Gerenciamento da AWS - com senha

Tipo de senha do console Personalizado

Exigir redefinição de senha Não

Limite de permissões Limite de permissões não definido

Administrator

____ datalake_admin

Welcome to Lake Formation

×

The first step in creating your data lake in Lake Formation is defining one or more administrators. Administrators have full access to the Lake Formation console, and control the initial data configuration and access permissions.

Choose the initial administrative users and roles

You may add yourself and/or other principals.

Add myself

AWS account: 575556700570

Add other AWS users or roles

Select additional IAM users and roles to be data lake administrators.

Choose IAM principals to add



Administrator X

Choose up to a maximum of 10 data lake administrators.

Cancel

Get started

12)

-Criação do CloudTrail pelo Wizard:

Criação da permissão da função para acessar o objeto do s3 CloudTrail

```
"Version": "2012-10-17",
"Statement": [
       "Effect": "Allow",
       "Action": "s3:GetObject",
       "Resource": ["arn:aws:s3:::aws-cloudtrail-logs-575556700570-99c9a596/*"]
                          Permissões da função
                      AWSGlueServiceRole
                          DatalakeGetCloudTrail.
```

Link do Lake Formation para o Path do S3

LakeFormationWorkflowRole

Register location

Amazon S3 location Register an Amazon S3 path as the storage location for your data lake. Amazon S3 path Choose an Amazon S3 path for your data lake. s3://rafaignaulin-datalake-cloudtrail Browse Review location permissions - strongly recommended Registering the selected location may result in your users gaining access to data already at that location. Before registering a location, we recommend that you review existing location permissions on resources in that location. **Review location permissions** To add or update data, Lake Formation needs read/write access to the chosen Amazon S3 path. Choose a role that you know has permission to do this, or choose the AWSServiceRoleForLakeFormationDataAccess service-linked role. When you register the first Amazon S3 path, the service-linked role and a new inline policy are created on your behalf. Lake Formation adds the first path to the inline policy and attaches it to the service-linked role. When you register subsequent paths, Lake Formation adds the path to the existing policy. OrganizationAccountAccessRole

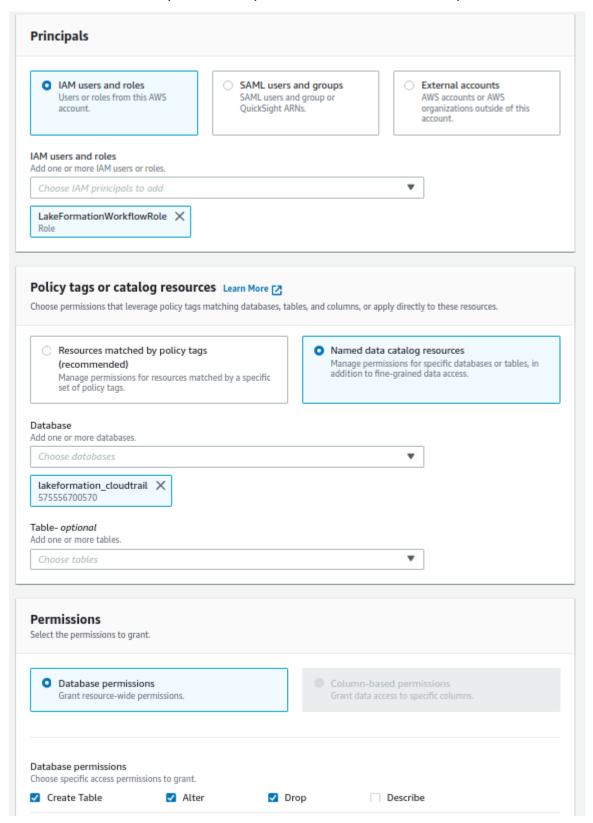
Register location

Cancel

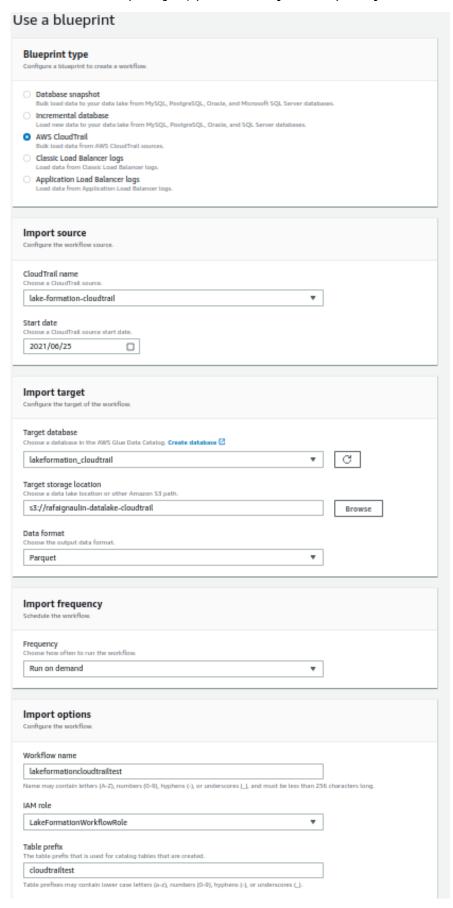
- Concedendo permissão para o s3 usando as políticas do IAM

My account User or role from this AWS account.	O External account AWS account or AW outside of my account	/S organization
IAM users and roles Add one or more IAM users or roles. Choose IAM principals to add LakeFormationWorkflowRole	▼	
Active Directory and Amazon QuickSight us Enter an Active Directory ARN (EMR beta only), An Enter to add additional ARNs.	nazon QuickSight ARN, or fede	
Storage locations Choose one or more data lake locations.	er/ <samlprovidernan< th=""><th></th></samlprovidernan<>	
e.g.: s3://bucket/prefix/ arn:aws:s3:::rafaignaulin-datalake-cloudte	rail X	Browse
Registered account location The account where this storage location is register 575556700570	ed in AWS Lake Formation.	
Grantable		

- Concedendo permissões para o database usando as políticas do IAM



- Criando um blueprint(job) para execução e importação do cloudTrail.



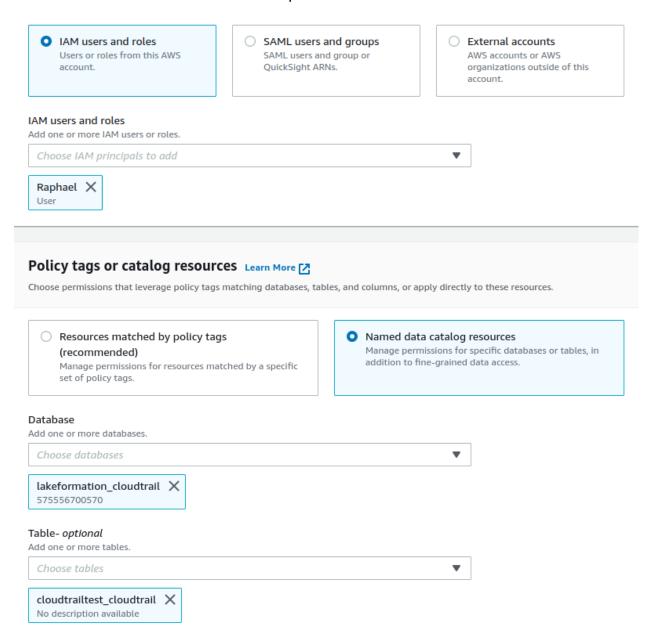
Blueprint Concluído

lakeformationcloudtrailtest

Fri, 25 Jun 2021 19:40:...

Concluído

 Criando permissões para um terceiro usuário (Analista de Dados) para acessar as queries no Athena.



- Dentro do Athena, com o database 'lakeformation_cloudtrail' criado e a tabela de 'cloudtrailtest_cloudtrail' criada.

